

Дообучение NanoVLM для управления агентом в MiniGrid EmptyEnv

github.com/nvclon/tbank-nanovlm-minigrid

1 Задача и данные

В работе реализован пайплайн дообучения NanoVLM для управления агентом в среде MiniGrid-Empty-8x8-v0. На вход модель получает RGB-render состояния среды, на выходе генерирует следующее действие. Сравниваются SFT на экспертных траекториях, дообучение в стиле GRPO и два формата ответа: прямое действие и “текст + действие”.

Используются три действия MiniGrid:

`left = 0, right = 1, forward = 2.`

Для сбора данных использовался shortest-path эксперт. Он получает privileged state симулятора: позицию агента, направление агента и позицию цели. В EmptyEnv нет внутренних препятствий, поэтому такой эксперт оптимален и воспроизводим. Важно, что privileged state используется только для разметки датасета; модель во всех экспериментах видит только RGB-изображение.

Было собрано 3000 train episodes, 300 validation episodes и 300 test episodes. В датасете есть дисбаланс действий: `forward` встречается чаще, чем повороты. Это влияет на поведение моделей, особенно при слабом обучении или zero-shot запуске.

2 Форматы ответа и SFT

Проверялись два формата ответа.

Action-only:

`forward`

Text+action:

Observation: The goal is not directly in front of the agent.

Plan: Turn right to face a better direction.

Action: right

Для text+action парсер извлекает финальное поле Action: Если корректное действие не найдено, ответ считается invalid.

Перед SFT был проверен zero-shot baseline с промптом, объясняющим объекты MiniGrid и допустимые действия. Модель генерировала валидные слова, но не управляла агентом: ответы схлопывались почти всегда в одно действие. Поэтому SFT оказался необходим не только для выбора действия, но и для устойчивого следования формату.

В SFT vision encoder оставался замороженным. Для action-only обучался modality projector. Для text+action лучший результат дал режим, где обучались modality projector и последний блок language decoder. Отдельно проверялся вариант, где обучался только последний decoder block из base-модели. Он стал лучше держать формат, но почти всегда выбирал `forward`, поэтому качество управления оставалось низким. Это показывает, что для MiniGrid важно адаптировать связку между visual features и language decoder, но не обязательно обучать весь vision encoder.




Figure 1: Validation loss при SFT.

3 Дообучение в стиле GRPO

RL-дообучение запускалось от соответствующего SFT checkpoint:

SFT-action -> GRPO-action, SFT-text+action -> GRPO-text+action

Из-за ограничения GPU в 6GB для **action-only** использовался облегчённый one-step вариант в стиле GRPO. Для одного состояния модель сэмплирует группу кандидатных первых действий. Для каждого действия считается reward через rollout, после чего reward нормализуется внутри группы:


$$A_i = \frac{R_i - \text{mean}(R)}{\text{std}(R) + \epsilon}.$$

Затем модель обновляется через log-probability выбранного действия:


$$\mathcal{L} = -A_i \log \pi(a_i | s).$$

Для **GRPO-action** использовалось constrained sampling по трём допустимым строкам: **left**, **right**, **forward**. Это убирает invalid-ответы и позволяет напрямую считать log-probability действия. В результате **GRPO-action** немного улучшил среднюю длину эпизода по сравнению с **SFT-action**.

Для **GRPO-text+action** использовалась свободная генерация текста. После генерации парсилось поле **Action: ...**, а log-probability всего completion пересчитывалась отдельным forward pass. В финальном запуске модель генерировала слишком однообразные ответы: внутри каждой группы все samples приводили к одному действию и одинаковому reward. Поэтому **reward_std** был равен нулю, **advantages** были нулевыми, и обновления не меняли модель. Это важное ограничение такого подхода: для свободного текстового формата нужна дополнительная exploration-регуляризация.



(a) GRPO-action



(b) GRPO-text+action


Figure 2: Group reward std во время GRPO. Для text+action дисперсия reward равна нулю, поэтому эффективных обновлений не происходит.

4 Результаты


Финальная оценка проводилась на 20 эпизодах с `max_episode_steps=30`. Для всех методов использовался одинаковый протокол. Для **SFT-action** выбран checkpoint `step_1000`, так как он дал лучший closed-loop результат среди сохранённых checkpoint'ов.

Метод	Success	Return	Steps	Invalid	Комментарий
Zero-shot NanoVLM	0.00	0.0000	30.00	0.00	Почти всегда одно действие
Forward baseline	0.10	0.0984	27.45	0.00	Всегда forward
Expert	1.00	0.9787	6.05	0.00	Shortest-path
SFT-action	1.00	0.9773	6.45	0.00	
GRPO-action	1.00	0.9787	6.05	0.00	Небольшое улучшение над SFT-action
SFT-text+action	1.00	0.9787	6.05	0.00	
GRPO-text+action	1.00	0.9787	6.05	0.00	Обновления не изменили модель

Table 1: Финальная closed-loop оценка.



(a) Success rate



(b) Средняя длина эпизода

Figure 3: Сравнение финальных моделей.

5 Выводы

SFT оказался достаточным для решения **EmptyEnv**: среда простая, полностью наблюдаемая, и expert labels почти напрямую задают нужную политику. Поэтому после SFT метрика success rate быстро

достигает потолка, а более информативными становятся average return, average steps, invalid rate и распределение действий.

GRPO-action дал небольшое улучшение: средняя длина эпизода уменьшилась с 6.45 до 6.05. Для text+action SFT также достиг 100% success rate, но GRPO не дал дополнительного улучшения, так как свободная генерация была слишком детерминированной и не создавала различий внутри групп.

Основные ограничения текущего решения:

- EmptyEnv слишком простая среда, поэтому SFT быстро достигает потолка;
- zero-shot NanoVLM чувствителен к промпту и склонен выбирать одно действие;
- для text+action GRPO нужна более сильная exploration-регуляризация (сейчас даже при высокой температуре разницы почти нет);
- текущий GRPO-action является облегчённым one-step вариантом, а не полным trajectory-level RL.

Что можно улучшить дальше:

- проверить большие карты, например MiniGrid-Empty-16x16-v0;
- перейти к более сложным средам: DoorKey, FourRooms;
- использовать LoRA вместо обучения последнего decoder block;
- сравнить free-form generation и constrained decoding для формата text+action. Сейчас свободная генерация выглядит более честной, но она медленнее и хуже даёт разнообразие для GRPO.
- сравнить методы не только по числу шагов, но и по времени. Для text+action генерация длиннее и заметно дороже, поэтому одинаковый success rate не означает одинаковую практическую эффективность.